CC3045 Deep Learning · Examen parcial

RemesaSegura S.A.: recomendación del comité técnico

Sistema de detección de lavado en remesas Guatemala–EE. UU. · 6,000 remitentes/día · prevalencia 0.2% (≈12 casos/día)

Decisión: **LANZAR CON CONDICIONES**

- **Umbral:** U4 el lunes con 8 analistas (≈36 alertas/día) → U3 con 14 → U2 con 50.
- **Cifra que más pesó:** 40 revisiones/día de capacidad frente a ≈250 alertas/día del piloto en U2.
- **Métricas reales:** precisión 3.9% en U2 (no 0.95); AUC temporal 0.81 (no 0.87).
- **Principal riesgo:** en U4 quedan ≈6 de 12 casos/día sin detectar (≈USD 300,000/día).

Contenido: Parte 1, Integración y decisión · Parte 2, Presentación y defensa · Parte 3, Análisis de los siete roles

Parte 1 · Integración y decisión (Task 2)

Insumos: `task1/rol-1.md` … `task1/rol-7.md`. Base común: 6,000 remitentes/día, prevalencia 0.2% → **12 positivos y 5,988 negativos por día**.

2.1 Conciliar las siete secciones

2.1.a Cifra clave por rol (exposición de 1 minuto) y dependencias

Rol	Cifra clave	Recomendación	Depende de
1	Precisión real U2 = **3.9%** (no 0.95); val. mínima 0.21 en época 6	Parada temprana + regularización + BCE ponderada/focal	Prevalencia (caso), piloto (Rol 7), validación temporal (Rol 3)
2	AUC 0.87 (aleatoria) con 18% params y 1.5 GPU-h	Ajuste fino de 2 bloques; LoRA como alternativa	AUC temporal (Rol 3)
3	AUC temporal **0.81** (−0.06)	Validación temporal por remitente; ventana ≥ 31 días	Métricas de Roles 1 y 2
4	AUC temporal 0.81 → **0.83** con difusión; 3% casi duplicados	Sintéticos de difusión solo en entrenamiento, filtrados	Base 0.81 (Rol 3); privacidad (Rol 6)
5	Alucinación 15% → **5%**; ahorro 4.5 min (75%)	LLM solo borrador, con contexto y T = 0.2	Volumen de alertas (Rol 7); SHAP (Rol 6)
6	SHAP error 3×10^{-7}; atención–SHAP ρ = 0.35	SHAP oficial; sin contrafactuales al cliente	AUC temporal (Rol 3), narrativas (Rol 5)
7	Capacidad **40/día** vs **250/día** del piloto	Lanzar con condiciones, escalonado	Tabla de umbrales (Rol 1)

2.1.b Cifras que no coinciden

Cifras en conflicto	Cuál usar	Por qué ambas son ciertas	Efecto en la decisión
Precisión U2: **0.95** (Rol 1) vs **≈4%** (piloto, Rol 7)	**3.9%**	0.95 se midió con validación 50/50. Recall y FPR no dependen de la prevalencia, la precisión sí: con 0.2%, 9.6 TP frente a 239.5 FP → 3.9%. El piloto (≈250 alertas, 10 confirmados) lo reproduce.	≈25 de cada 26 alertas son falsas: el costo de revisión manda. Cada caso confirmado en U2 cuesta ≈ USD 311 en revisión.
AUC **0.87** (Roles 1–2) vs **0.81** (Rol 3)	**0.81**	0.87 usa partición aleatoria de ventanas: hay fuga entre ventanas del mismo remitente y autocorrelación. 0.81 usa ene–mar → abr–may.	La gerencia y el regulador reciben 0.81. La tabla de umbrales del Rol 1 es optimista.
AUC **0.83** (Rol 4) vs **0.81** (Rol 3)	**0.81** (0.83 queda pendiente)	Ambas son temporales. 0.83 añade sintéticos de difusión, pero antes del filtrado de privacidad (3% casi copias).	La mejora de +0.02 no entra en la decisión hasta repetirla después del filtrado.
Alertas U2: tabla **≈249** y 9.6 TP vs piloto **≈250** y **10** confirmados	Ambas	La tabla aplica recall/FPR a 6,000 remitentes. El piloto es la observación real. La diferencia (10 vs 9.6, recall 0.83 vs 0.80) es ruido de dos semanas.	U2 es el único punto de operación validado en producción. U3 y U4 solo tienen cifras de la tabla optimista.
Capacidad **40/día** vs **250/día**	Ambas	Una es oferta (8 × 5) y la otra demanda (piloto U2).	En U2 quedan 210 alertas/día (84%) sin revisar, lo que viola "cada alerta revisada por una persona".

Cifras en conflicto	Cuál usar	Por qué ambas son ciertas	Efecto en la decisión
Ahorro LLM **180 min/día** vs **1,125 min/día** (Rol 5)	180 min con la capacidad actual	El ahorro escala con las alertas revisadas: 40 o 250 por día.	El LLM no resuelve la brecha de capacidad, porque el README no da el tiempo total de revisión por alerta.
Pérdidas de entrenamiento (0.08) vs validación (0.34) del Rol 1	La tendencia, no el nivel	Entrenamiento usa la prevalencia real; validación es 50/50, así que los niveles no son comparables.	El diagnóstico de sobreajuste se basa en el mínimo de la época 6 y la subida posterior.

2.1.c Cifras optimistas

1. **Precisión 0.90–0.99** (Rol 1): validación 50/50; la real es 1.8%–16.7%.
2. **AUC 0.87** y todo el ranking de estrategias del Rol 2: partición aleatoria. Solo la estrategia elegida tiene AUC temporal (0.81).
3. **Recall/FPR de la tabla del Rol 1**: modelo de la época 20 (sobreajustado) y partición aleatoria. El piloto confirma U2, pero U3 y U4 no están validados.
4. **AUC 0.83** con sintéticos: medido antes del filtrado de privacidad; +0.02 es modesto.
5. **5% de alucinación**: n = 40, IC 95% de 1.4% a 16.5%.
6. **Exactitud 99.8%**: es trivial, la alcanza un sistema que nunca alerta.
7. **Piloto: 4% confirmadas y 83% de detección:** con capacidad de 40/día no se pudieron revisar las ≈250 alertas/día. El 4% salió de una muestra o de personal extra que el caso no describe. El 83% (10 de 12) compara contra una estimación previa de 12 casos, no contra casos medidos.
8. **12 casos/día esperados**: solo cuenta lo confirmable con las tipologías conocidas (7, una sin cubrir por sintéticos). La exposición real podría ser mayor.

2.2 Umbral, capacidad y decisión

2.2.a Tabla por umbral

TP = recall × 12; FP = FPR × 5,988; alertas = TP + FP; precisión = TP / alertas; costo = alertas × USD 12; daño esperado = no detectados × USD 50,000; analistas = alertas / 5.

Umbral	Alertas diarias esperadas	Casos detectados	Casos no detectados	Precisión esperada	Costo diario de revisión	Daño esperado por no detectados	Costo total/día	Analistas necesarios
U1	609.6	10.8	1.2	1.8%	USD 7,315	USD 60,000	USD 67,315	122
U2	249.1	9.6	2.4	3.9%	USD 2,989	USD 120,000	USD 122,989	50
U3	67.7	7.8	4.2	11.5%	USD 812	USD 210,000	USD 210,812	14
U4	35.9	6.0	6.0	16.7%	USD 431	USD 300,000	USD 300,431	8 (7.2)

Costo marginal de bajar el umbral:

Paso	Revisión adicional/día	Casos adicionales detectados	Daño evitado/día
U4 → U3	USD 381	1.8	USD 90,000
U3 → U2	USD 2,177	1.8	USD 90,000

Paso	Revisión adicional/día	Casos adicionales detectados	Daño evitado/día
U2 → U1	USD 4,326	1.2	USD 60,000

2.2.b Umbral y capacidad elegidos

- **Restricción dura:** cada alerta debe ser revisada por una persona. Con 8 analistas (40/día), el único umbral que cabe es **U4** (≈36 alertas/día).
- **Criterio económico:** cada paso hacia un umbral más bajo evita mucho más daño del que cuesta revisar (USD 381 por USD 90,000 en el peor caso). Mantenerse en U4 deja ≈ USD 300,000/día de daño esperado, contra ≈ USD 123,000 en U2.
- **Por qué U2 como objetivo y no U1:** U1 minimiza el costo total teórico, pero exige 122 analistas, tiene una precisión de 1.8% (fatiga de revisión) y nadie lo ha validado. U2 es el único punto confirmado por el piloto (≈250 alertas, 10 confirmados). Si U1 se revalida con partición temporal, podrá evaluarse después.
- **Elección:**
  - Lunes: **U4 con 8 analistas** (36 alertas de 40 posibles, USD 431/día).
  - Escalón intermedio: **U3 con 14 analistas** (68/día, USD 812/día).
  - Objetivo: **U2 con 50 analistas** (250/día, USD 3,000/día), 10 casos confirmados por día (83% de 12).

2.2.c Decisión: LANZAR CON CONDICIONES

Condiciones medibles (los plazos son propuesta del grupo):

1. **Cobertura humana:** 0 alertas sin revisar por día. Las alertas diarias no superan 5 × analistas activos. Bajar de umbral solo cuando la capacidad lo permita: U3 con ≥ 14 analistas, U2 con ≥ 50.
2. **Modelo corregido y revalidado antes de bajar de U4:** reentrenado con parada temprana (mejor época por pérdida de validación), regularización y BCE ponderada o focal, y validado con partición temporal por remitente. AUC temporal ≥ 0.81 y recall temporal ≥ 0.80 en el umbral objetivo, con la tabla de umbrales recalculada a prevalencia real.
3. **Narrativas LLM:** solo con contexto y T ≤ 0.2. El 100% pasa el validador automático de montos, fechas e IDs. Meta de 0 hechos inventados en las narrativas enviadas, con auditoría muestral mensual (≥ 40 narrativas).
4. **Explicabilidad:** SHAP aprueba las pruebas de fidelidad y estabilidad (Jaccard top-5 ≥ 0.90 entre fondos, propuesta del Rol 6). Cero contrafactuales en comunicaciones al cliente.
5. **Privacidad y transferencia:** sintéticos usados solo tras el filtrado (0 casi duplicados de clientes reales). Montos re-normalizados a la escala del socio, con deriva de montos monitoreada mensualmente (PSI o KS).
6. **Monitoreo de desempeño:** recall y precisión mensuales sobre casos confirmados. Si la precisión de U2 cae por debajo de 3% o las alertas/día exceden la capacidad, se sube el umbral y se informa al comité.

2.3 Errores y limitaciones de la IA

Casos reales de esta sesión de trabajo con IA (Claude Code y sus subagentes). Agregar los hallazgos del agente que está verificando los cálculos. No inventar casos.

Caso	Respuesta de la IA	Supuesto incorrecto / información omitida	Verificación realizada
1	La IA del Rol 1 justificó que la BCE sin ponderar es inadecuada con "un predictor constante p = 0.002 obtiene BCE ≈ 0.014".	La cifra es correcta, pero la IA no notó que contradice el dato del caso: la pérdida de entrenamiento final (0.08) sería *peor* que la de un predictor constante. Omitió reconciliarlo o advertirlo.	Cálculo manual: −(0.002·ln 0.002 + 0.998·ln 0.998) = 0.0124 + 0.0020 = **0.0144**. Se marcó la frase como riesgosa para la defensa.

Caso	Respuesta de la IA	Supuesto incorrecto / información omitida	Verificación realizada
2	La IA aplicó la tabla de umbrales del Rol 1 directamente a producción (alertas, casos detectados y costos por umbral) para elegir U4/U3/U2.	Esa tabla sale del modelo de la época 20 (sobreajustado) y de partición aleatoria; el AUC temporal cae de 0.87 a 0.81. La IA no ajustó recall y FPR por esa degradación.	Se comparó con el piloto: U2 predice 249 alertas y 9.6 TP; el piloto observó ≈250 y 10. U2 queda corroborado; U3 y U4 se declaran no validados y se exige revalidación (condición 2).
3	La IA del Rol 7 calculó el costo de pasar de U4 a U2 como 210 × 12 = USD 2,520/día, frente a 3.6 casos más (USD 180,000).	Mezcló bases: el costo se midió contra la capacidad actual (40 alertas) y el beneficio contra U4 (36 alertas).	Lo detectó un segundo agente verificador. Recalculado: (249.1 − 35.9) × 12 = **USD 2,558/día**. La conclusión no cambia; se corrigió `rol-7.md`.
4	Las IA de los Roles 1, 3 y 7 usaron el piloto (≈250 alertas, 4% confirmadas, 10 de 12 casos = 83%) como evidencia de que U2 funciona.	Omitieron que con 40 revisiones/día no pudieron revisarse las 250 alertas, así que el 4% viene de una muestra o de personal extra. Además, los 12 casos son una estimación, no una medición.	Lo detectó el agente verificador. Comprobación: 250 > 40 = 8 × 5. Se agregó a cifras optimistas (2.1.c, punto 7).
5	La IA del Rol 3 recomendó una ventana de exactamente 30 días para captar el rezago de 30.	Una ventana de 30 días solo contiene rezagos de 0 a 29, no el de 30.	Lo detectó el agente verificador. Se cambió a "al menos 31 días" en `rol-3.md`.
6	Las IA de los Roles 5 y 7 afirmaron que el ahorro del LLM (4.5 min por narrativa) no aumenta la capacidad de 5 alertas por analista.	Es un supuesto no explícito: el caso no da el tiempo total de revisión por alerta, así que tampoco se puede afirmar que el ahorro no cuente.	Se revisó el enunciado: no hay dato de minutos por revisión completa. Queda como limitación, no como conclusión.

2.3.b Verificación manual de un resultado de la 2.2 (U2): 0.80 × 12 = 9.6 TP. 0.04 × 5,988 = 239.52 FP. Alertas = 249.12. Precisión = 9.6 / 249.12 = 3.85%. Costo = 249.12 × 12 = USD 2,989.44. No detectados = 2.4 → 2.4 × 50,000 = USD 120,000. *Un integrante debe rehacerlo a mano antes de entregar.*

2.4.a Defensa ante el regulador (≤ 6 líneas)

Presentamos la validación temporal del modelo (AUC 0.81, entrenamiento ene–mar y validación abr–may) y un piloto de dos semanas en U2 (≈250 alertas/día, 10 casos confirmados/día, 83% de los 12 esperados). También presentamos explicaciones SHAP por alerta (error de eficiencia 3×10^{-7}) y el registro auditable de la revisión humana de cada alerta. Reconocemos un riesgo residual: hasta ampliar el equipo, en U4 dejaremos de detectar ≈6 de 12 casos/día, y el modelo puede degradarse por deriva del corredor. Nos comprometemos a informar mensualmente recall, precisión, deriva de montos, auditoría de narrativas y una cola de alertas sin revisar igual a 0, y a bajar el umbral a U3 y luego a U2 conforme crezca la capacidad. La decisión la asume la Gerencia General a propuesta de este comité; el Oficial de Cumplimiento responde por la operación y el reporte.

2.4.b–d Memo y entrega

- Memo armado en `task2/memo.html` y exportado a `task2/memo.pdf` (máximo 2 páginas).
- **Pendiente del grupo:** contribuciones individuales (2.4.c, con nombres reales y sus propias correcciones a la IA), revisión final y subida a Canvas cuando el docente avise (2.4.d).

Parte 2 · Presentación y defensa (Task 3)

Diapositiva: `task3/slide.pdf` (fuente: `slide.html`). Memo: `task2/memo.pdf`.

3.1 Guion de 2 minutos (≈280 palabras)

Lo puede decir una persona o repartirse por bloques. **Ensayar una vez con cronómetro** y anotar el tiempo: _____.

[0:00–0:20] Decisión. "Recomendamos **lanzar con condiciones**. La regla que manda es que cada alerta debe revisarla una persona de cumplimiento, y hoy el equipo puede revisar 40 alertas al día."

[0:20–0:50] La cifra que más pesó. "En el piloto con U2 el sistema generó unas **250 alertas diarias para 40 revisiones posibles**. Además, la precisión de 0.95 que reportó modelado venía de una validación mitad positivos y mitad negativos. Con la prevalencia real de 0.2%, la precisión es **3.9%**: unas 25 de cada 26 alertas son falsas. El AUC también estaba inflado: con partición temporal baja de 0.87 a **0.81**."

[0:50–1:20] Umbral y capacidad. "Por eso el lunes arrancamos en **U4 con los 8 analistas**: unas 36 alertas diarias, que caben en la capacidad, por USD 431 al día. Luego bajamos a U3 con 14 analistas y llegamos a **U2 con 50**, el único punto que el piloto corrobora, con unos 10 de 12 casos diarios detectados. Cada paso se justifica: pasar de U4 a U2 cuesta USD 2,558 diarios en revisión y evita unos USD 180,000 de daño esperado."

[1:20–1:45] Condiciones. "Las condiciones son medibles: - cero alertas sin revisar; - reentrenar con parada temprana y pérdida ponderada, y revalidar con partición temporal antes de bajar de U4; - narrativas del LLM con las transacciones en contexto, validador automático y firma del oficial; - SHAP como explicación, sin contrafactuales al cliente; - sintéticos de difusión solo después del filtro de privacidad."

[1:45–2:00] Riesgo y responsable. "El principal riesgo: en U4 dejamos de detectar unos **6 de 12 casos diarios** hasta ampliar el equipo, y lo reconocemos ante el regulador. La decisión la asume la Gerencia General a propuesta de este comité; el Oficial de Cumplimiento responde por la operación."

3.1.b Las siete secciones en una línea (todos deben saberlas)

§	Idea	Cifra
1 Modelado	Sobreajuste: parar en la época 6, regularizar, usar BCE ponderada o focal	Validación 0.21 → 0.34; precisión real U2 3.9%
2 Transferencia	Ajuste fino de 2 bloques con LR 10× menor; el ajuste completo sobreajusta con 1,200 positivos	AUC 0.87 / 18% parámetros / 1.5 GPU-h; temporal 0.81
3 Series de tiempo	La partición aleatoria filtra información entre ventanas del mismo remitente; ventana ≥ 31 días por los ciclos 7/15/30	AUC 0.87 → 0.81; exactitud trivial 99.8%
4 Generativos	Difusión solo para entrenar y prueba solo con datos reales; la GAN colapsa a un modo y el VAE promedia	6 de 7 tipologías; AUC 0.81 → 0.83; 3% casi copias
5 LLM	Borrador con contexto y T = 0.2, validador automático y firma humana	Alucinación 15% → 5%; ahorro 4.5 min (75%)
6 Explicabilidad	SHAP sí; LIME inestable; atención no; sin contrafactuales al cliente	SHAP 3×10^{-7}; LIME 0.45 / 0.78; ρ = 0.35
7 Operaciones	Capacidad 40 vs 250 → U4 al inicio y ampliar a U3 y U2	8 × 5 = 40; 250 × 12 = USD 3,000; 10 de 12 = 83%

3.2 Preguntas probables y respuestas cortas

Decisión y números

- **¿Por qué no lanzar en U2 directamente?** Con 8 analistas solo se revisan 40 de 250 alertas; 210 diarias quedarían sin revisión humana, y el caso exige revisar cada una.
- **¿Por qué no "no lanzar"?** Cada día sin sistema se pierde detección. Incluso U4 detecta unos 6 casos diarios con alertas que caben en la capacidad. Bajar el umbral evita más daño del que cuesta (U4→U3: USD 381 frente a USD 90,000).
- **¿Por qué no U1, si minimiza el costo total?** Exige 122 analistas, tiene precisión de 1.8% (fatiga de revisión) y no está validado; el piloto solo corrobora U2.
- **¿Cómo calcularon las alertas?** TP = recall × 12; FP = FPR × 5,988; alertas = TP + FP. U2: 9.6 + 239.5 = 249.1. Precisión 9.6 / 249.1 = 3.85%.
- **¿Por qué 0.95 y 3.9% son ambas ciertas?** Recall y FPR no dependen de la prevalencia; la precisión sí. Con 50/50 hay tantos positivos como negativos; con 0.2% los negativos son 499 veces más.
- **¿Qué cifra es optimista?** El AUC 0.87 (partición aleatoria), la precisión de 0.90 a 0.99 (50/50), el AUC 0.83 (antes del filtro de privacidad), el 5% de alucinación (n = 40) y el propio piloto: con 40 revisiones diarias no se revisaron las 250 alertas, así que el 4% viene de una muestra.

Por sección

- **(1) ¿Qué muestran las curvas?** El entrenamiento baja de 0.42 a 0.08 mientras validación sube de 0.21 (época 6) a 0.34: sobreajuste. Se evaluó el peor checkpoint (época 20).
- **(1) ¿Por qué no BCE sin ponderar?** Con 0.2% de positivos los negativos dominan la pérdida, y predecir "nunca" ya da pérdida baja. Con pos_weight ≈ 499 (0.998 / 0.002) o focal loss se fuerza a aprender los positivos.
- **(2) ¿Por qué el ajuste completo rinde menos con menor pérdida de entrenamiento?** Sobreajusta: tiene 100% de parámetros para 1,200 positivos y olvida lo aprendido con 3 millones de secuencias (olvido catastrófico).
- **(2) ¿Riesgo de usar el modelo del socio?** Otra escala de normalización de montos y otra distribución de montos. Se verifica re-normalizando y midiendo la deriva (PSI o KS) con validación temporal propia.
- **(3) ¿Por qué ≥ 31 días y no 30?** Para observar el rezago de 30 hacen falta dos días separados por 30, y una ventana de 30 días solo cubre rezagos de 0 a 29.
- **(3) ¿Qué métrica en vez de exactitud?** Recall, precisión a prevalencia real, PR-AUC y recall con 40 alertas diarias. Un sistema que nunca alerta logra 99.8% de exactitud y detecta 0 casos.
- **(4) ¿Por qué la GAN cubre pocas tipologías?** Por colapso de modo: el generador solo necesita engañar al discriminador y se queda en un patrón que funciona.
- **(4) ¿Por qué el VAE es borroso?** La reconstrucción tipo MSE más la KL empuja hacia la media condicional, que promedia montos y borra patrones exactos.
- **(4) ¿Cómo se valida con sintéticos?** Se entrena con reales más sintéticos de enero a marzo y se prueba solo con reales de abril y mayo. Nunca se prueba con sintéticos.
- **(5) ¿Por qué alucina el LLM?** Genera el token más probable, no consulta hechos. Sin las transacciones inventa montos verosímiles, como USD 9,800, justo bajo el umbral de USD 10,000. El contexto le da hechos que copiar y la temperatura baja reduce el muestreo de tokens improbables.
- **(6) ¿Por qué SHAP y no atención?** El error de eficiencia de SHAP es 3×10^{-7}, así que las contribuciones suman exactamente el puntaje. La atención solo correlaciona 0.35 con SHAP: indica dónde mira el modelo, no cuánto aporta cada entrada.
- **(6) ¿Por qué no decirle al cliente qué cambiar?** Es un contrafactual que enseña a evadir el sistema, por ejemplo fraccionando montos, y alerta al sospechoso (*tipping-off*).

- **(7) ¿Cuántos casos detectó el piloto?** 4% × 250 = 10 por día, el 83% de 12. Ojo: 12 es una estimación y el 4% salió de una muestra.

Uso de la IA (pregunta segura)

- **¿Cómo usaron la IA?** Un agente por rol para la Task 1, un segundo agente verificador independiente y la integración con IA. Cada cifra se recalculó por separado.
- **¿Dónde falló?**
  - Mezcló bases en U4→U2 (USD 2,520 frente a 2,558 correctos).
  - Propuso una ventana de 30 días que no capta el rezago de 30.
  - Tomó el 4% del piloto sin preguntar cómo se revisaron 250 alertas con capacidad para 40.
  - Dio una pérdida de referencia (0.0144) que contradice el dato del caso.
  - Presentó umbrales propios, como Jaccard ≥ 0.90, sin fuente.
- **¿Cómo verificaron?** Recalculando a mano y con un script independiente, y comparando cada cifra con el PDF del examen. Cada integrante debe poder rehacer su corrección a mano (ver contribuciones en el memo).
- **¿Quién responde por la decisión?** La Gerencia General, a propuesta del comité técnico. El Oficial de Cumplimiento responde por la operación y el reporte. La IA no responde: es una herramienta.

Checklist antes de la defensa

- [ ] Ensayo cronometrado de 2:00 hecho (tiempo: ____)
- [ ] Cada integrante explicó en voz alta las 7 líneas de la tabla
- [ ] Cada integrante puede rehacer a mano su corrección a la IA
- [ ] Alguien recalculó U2 a mano (Task 2.3.b)

Parte 3 · Análisis por rol (Task 1)

Detalle de cada uno de los siete roles: incisos, sección del memo y cifras compartidas.

Rol 1 - Líder de modelado | Task 1.1 | Memo §1

1.1.a Diagnóstico de las curvas de pérdida y dos cambios

Diagnóstico: sobreajuste a partir de la época 6. La pérdida de entrenamiento baja de forma continua (0.42 → 0.08), pero la de validación toca su mínimo de **0.21 en la época 6** y después sube hasta **0.34 en la época 20** (+0.13, un 62% más). A partir de la época 6 el modelo memoriza el conjunto de entrenamiento (donde hay muy pocos positivos) en lugar de generalizar. Además se evaluó y reportó el modelo de la **época 20**, con una pérdida de validación 0.13 mayor que la de la época 6: las métricas de la tabla corresponden a un modelo sobreajustado. Hay que agregar que el *nivel* absoluto de ambas pérdidas no se compara directamente, porque entrenamiento usa la prevalencia real y validación está remuestreada al 50/50. La señal de sobreajuste está en la *tendencia*: validación sube mientras entrenamiento sigue bajando.

#	Cambio concreto	Qué problema corrige
1	**Parada temprana con restauración del mejor checkpoint**: monitorear la pérdida de validación, paciencia de unas 3 épocas, y quedarse con los pesos de la mejor época (aquí la 6, val = 0.21) en vez de los de la 20.	Que el modelo entregado siga entrenando después del punto óptimo. Elimina las 14 épocas de memorización y entrega el modelo con menor error de generalización observado.
2	**Regularización explícita**: *weight decay* (L2, p. ej. AdamW con 1e-4 a 1e-2) y *dropout* (0.2 a 0.3) en la cabeza clasificadora y en las capas densas.	La alta capacidad sin restricciones (hoy no hay ninguna regularización). Penaliza pesos grandes y la co-adaptación de neuronas, lo que reduce la brecha entre entrenamiento y validación y retrasa o suaviza el sobreajuste.

Los dos cambios se complementan: la regularización reduce el sobreajuste y la parada temprana elige el mejor punto que queda. Para escoger la época y los hiperparámetros hay que usar una **validación temporal** (ver Rol 3), no una aleatoria.

1.1.b ¿Es apropiada BCE sin ponderar con 0.2% de positivos?

No. Con 0.2% de positivos, el 99.8% de los términos de la pérdida provienen de negativos, así que el gradiente lo dominan los negativos. El modelo puede bajar mucho la pérdida si predice casi siempre una probabilidad cercana a 0. Como referencia, un predictor constante p = 0.002 logra BCE ≈ 0.014 sin detectar ningún caso. Por eso un valor bajo de pérdida no garantiza que el modelo detecte lavado: los ~12 positivos diarios casi no influyen en el aprendizaje, y la frontera de decisión de los positivos queda mal estimada.

Alternativa justificada: BCE **ponderada** con `pos_weight = 0.998 / 0.002 = 499`, que hace que positivos y negativos aporten lo mismo en total a la pérdida. Si 499 vuelve inestable el entrenamiento (gradientes ruidosos con tan pocos positivos), conviene una versión moderada, p. ej. √499 ≈ 22, y fijar el valor por validación. Otra opción es la **focal loss** (γ ≈ 2, α según la clase), que baja el peso de los negativos fáciles y concentra el aprendizaje en los ejemplos difíciles. **Precauciones:** - La ponderación o la focal loss **descalibran** las probabilidades (las inflan para la clase positiva). Hay que recalibrar después (Platt o isotónica) sobre datos con la prevalencia real. - El **umbral** de alerta se fija al final, con la prevalencia real (0.2%) y la capacidad de revisión, no con 0.5 ni con la validación 50/50.

Advertencia sobre la tabla de umbrales

Las métricas de la tabla se calcularon con **validación remuestreada 50/50**, **partición aleatoria** y el **modelo de la época 20**. Recall y FPR son tasas condicionadas a la clase y **no dependen de la prevalencia**. La **precisión sí depende**: con 50% de positivos se infla artificialmente. Con 6,000 remitentes/día y 0.2% hay **12 positivos y 5,988 negativos**: TP = recall × 12, FP = FPR × 5,988, precisión = TP / (TP + FP).

Umbral	Recall	FPR	TP/día	FP/día	Alertas/día	Precisión reportada (50/50)	Precisión real (0.2%)
U1	0.90	0.10	10.8	598.8	≈ 610	0.90	**1.8%**

Umbral	Recall	FPR	TP/día	FP/día	Alertas/día	Precisión reportada (50/50)	Precisión real (0.2%)
U2	0.80	0.04	9.6	239.5	≈ 249	0.95	**3.9%**
U3	0.65	0.01	7.8	59.9	≈ 68	0.98	**11.5%**
U4	0.50	0.005	6.0	29.9	≈ 36	0.99	**16.7%**

Comprobación: en U2 el cálculo da ≈ 249 alertas/día con 3.9% de precisión, lo que coincide con el piloto del Rol 7 (≈ 250 alertas/día, ~4% confirmadas). La precisión de 0.95 reportada no describe la operación real.

Sección 1 del memo

§1 Modelado. El modelo evaluado (época 20) está sobreajustado: la pérdida de validación subió de 0.21 (época 6) a 0.34. Recomendamos reentrenar con parada temprana (restaurando el mejor checkpoint), *weight decay* y *dropout*, y BCE ponderada (`pos_weight` hasta 499) o focal loss, con recalibración posterior. La precisión reportada de 0.90–0.99 proviene de una validación 50/50. Con la prevalencia real de 0.2%, la precisión es de 1.8% (U1) a 16.7% (U4), y en U2 sería **3.9% con ≈ 249 alertas/día**, en línea con el piloto. Ningún umbral debe fijarse hasta recalcular la tabla con el modelo corregido sobre partición temporal y prevalencia real.

Cifras a compartir / dependencias

- **Rol 3:** la tabla viene de partición **aleatoria** y validación **50/50**. Con partición temporal el AUC cae de 0.87 a 0.81, así que recall y FPR por umbral probablemente sean **optimistas**. Le pido la versión temporal para recalcular.
- **Rol 7:** alertas/día y precisión real por umbral (U2 ≈ 249 alertas y 3.9%, coherente con su piloto). Necesito su capacidad (8 × 5 = 40 alertas/día) y su costo (USD 12/alerta, USD 50,000 por caso no detectado) para elegir umbral.
- **Grupo (Task 2.2):** recall/FPR por umbral y la base de 12 positivos / 5,988 negativos. Supuestos que hay que declarar: (1) partición aleatoria, (2) validación 50/50 (solo la precisión se corrige con la prevalencia), (3) modelo de la **época 20**, que está sobreajustado. Las tres hacen que las cifras sean un **techo optimista**, no la expectativa de producción.

Rol 2 - Ingeniero de transferencia | Task 1.2 | Memo §2

Datos: codificador del socio preentrenado con 3 millones de secuencias de otro corredor; RemesaSegura tiene 1,200 positivos etiquetados. Las cinco estrategias se evaluaron con **partición aleatoria**.

1.2.a

Estrategia elegida: ajuste fino de los dos últimos bloques con tasa de aprendizaje 10× menor.

- **AUC:** 0.87, la mejor de la tabla. Supera por 0.09 a entrenar desde cero (0.78), por 0.05 a la extracción de características (0.82) y por 0.03 al ajuste fino completo (0.84).
- **Parámetros entrenables:** 18%, contra el 100% del ajuste completo. Hay menos capacidad para memorizar los 1,200 positivos.
- **GPU-horas:** 1.5, contra 6 del ajuste completo o de entrenar desde cero (4× menos cómputo).
- **Comparación con LoRA r=8 (0.86 | 2% | 1 GPU-h):** LoRA queda a solo 0.01 de AUC y usa 9× menos parámetros (2% frente a 18%) y 0.5 GPU-h menos. Es una **alternativa válida con menor riesgo de sobreajuste**. Una diferencia de 0.01 bajo partición aleatoria puede no ser significativa. Además, solo el ajuste de dos bloques tiene AUC temporal medido (0.81, Rol 3). Se elige esa estrategia como candidata y LoRA queda como respaldo: si con partición temporal LoRA iguala o supera a 0.81, se prefiere LoRA por ser más barata y más robusta.

¿Por qué el ajuste fino completo rinde menos (0.84) aunque logra una pérdida de entrenamiento mucho menor? 1. **Sobreajuste.** Con 100% de parámetros entrenables y solo 1,200 positivos, el modelo memoriza el conjunto de entrenamiento. La pérdida de entrenamiento baja, pero el modelo no generaliza a validación. 2. **Olvido catastrófico.** Actualizar todo el codificador con el LR completo borra las representaciones generales aprendidas con 3 millones de secuencias, y esos pocos datos propios no bastan para reconstruirlas. 3. **Por qué el ajuste parcial evita ambos problemas.** Congelar los bloques tempranos conserva los rasgos generales (patrones de secuencia, periodicidad, montos), y el LR 10× menor limita cuánto se alejan los bloques superiores de los pesos preentrenados. Ambos actúan como regularización.

1.2.b

Riesgo	Por qué importa	Cómo verificarlo / mitigarlo
Escala de normalización de montos distinta	El codificador recibe montos en otra escala, así que sus activaciones y desviaciones quedan desplazadas sin que nada lo indique.	Re-normalizar nuestros montos con la escala del socio, o reajustar la capa de entrada. Verificar que media, desviación y percentiles de la entrada normalizada coincidan con los del preentrenamiento.
Cambio de distribución (dominio)	Las distribuciones de montos de los dos corredores son diferentes, así que lo que el modelo considera "normal" no es el comportamiento normal de Guatemala–EE. UU.	Comparar las distribuciones de montos con pruebas KS o PSI. Revisar la distribución de la puntuación de desviación de la etapa 1 en datos propios. Validar con partición temporal en datos de RemesaSegura.
Patrones de lavado distintos entre corredores	Las tipologías del otro corredor pueden no coincidir con las 7 conocidas aquí, y el codificador puede no captar algunas.	Medir el recall por tipología en datos propios y revisar los falsos negativos con cumplimiento.
AUC inflado por partición aleatoria	Ventanas del mismo remitente quedan en entrenamiento y en validación (fuga de información).	Reportar solo el AUC temporal: **0.87 → 0.81** (enero–marzo / abril–mayo, Rol 3). Re-evaluar LoRA con la misma partición.
Gobernanza y procedencia del modelo del socio	Ante el regulador hay que justificar con qué datos se entrenó el modelo, si había consentimiento para usarlos y quién responde por él.	Obtener documentación de los datos, el preprocesamiento y la licencia. Versionar los pesos recibidos.

Sección 2 del memo

Recomendamos adaptar el codificador del socio con **ajuste fino de los dos últimos bloques y LR 10× menor**: es la mejor estrategia evaluada (AUC 0.87) con 18% de parámetros entrenables y 1.5 GPU-h, frente a 0.84 del ajuste completo, que sobreajusta con solo 1,200 positivos. LoRA r=8 (0.86, 2% de parámetros, 1 GPU-h) queda como alternativa de menor riesgo. **El AUC que debe reportarse a gerencia es el temporal, 0.81, no 0.87**, porque esta última cifra se midió con partición aleatoria. Condición previa al lanzamiento: re-normalizar los montos a la escala del socio y verificar la deriva entre corredores con PSI o KS.

Cifras a compartir / dependencias

- **Para Rol 3:** las 5 estrategias se midieron con partición aleatoria. Solo la elegida tiene AUC temporal (0.87 → 0.81, una caída de 0.06). LoRA (0.86) y las demás estrategias aún no tienen AUC temporal.
- **Para Rol 4:** el AUC base para medir datos sintéticos es el temporal 0.81 de esta estrategia.
- **Para el grupo (Task 2.1):** la cifra optimista es 0.87 y la que se concilia es 0.81. El costo de entrenamiento es bajo (1.5 GPU-h). Riesgos abiertos: escala de normalización, deriva de dominio y procedencia del modelo del socio.
- **Dependencia:** la elección final entre el ajuste de dos bloques y LoRA depende de la validación temporal del Rol 3.

Rol 3 - Analista de series de tiempo | Task 1.3 | Memo §3

Datos de partida (README): ventanas de 10 transacciones por remitente; Roles 1 y 2 usaron partición aleatoria de ventanas; partición temporal del candidato (ajuste fino de dos bloques: train ene–mar, val abr–may) da AUC 0.87 → 0.81; autocorrelación del monto diario con picos a 7, 15 y 30 días; un sistema que nunca alerta logra 99.8% de exactitud; 6,000 remitentes/día, prevalencia 0.2% (≈12 casos/día).

1.3.a

- **Fuga entre particiones:** al repartir ventanas al azar, ventanas del **mismo remitente** quedan en entrenamiento y en validación. Las ventanas contiguas o solapadas de una secuencia están autocorrelacionadas (picos a 7, 15 y 30 días), así que la validación contiene casi copias de lo que el modelo ya vio. El modelo **reconoce al remitente o al periodo** en vez de generalizar a remitentes y meses nuevos.
- **Futuro para predecir pasado:** la partición aleatoria mete en el entrenamiento ventanas posteriores a las de validación. En producción el modelo solo tendrá el pasado. Además, no mide la deriva entre meses.
- **Efecto medido:** con partición temporal el AUC del candidato baja de **0.87 a 0.81 (−0.06)**. **La gerencia debe usar 0.81**. El 0.87 es optimista porque mide memoria del remitente, no detección.
- **Recomendación de protocolo:** partición temporal (ene–mar → abr–may) **y además agrupada por remitente** (ningún remitente en ambos lados). Agregar un **hueco o embargo de ≥ 30 días**, el mayor rezago con autocorrelación, o al menos descartar las ventanas que cruzan la frontera. Repetir el esquema con origen móvil para ver la estabilidad mes a mes.

1.3.b

- **Interpretación:** los picos a **7, 15 y 30 días** muestran ciclos **semanal, quincenal y mensual**. Esto coincide con el envío de remesas atado al pago de salario (semana, quincena, fin de mes). Un monto alto el día de pago es normal, no una anomalía.
- **Problema de la ventana actual:** 10 transacciones no corresponden a un horizonte fijo de días. Para un remitente frecuente cubren una o dos semanas (no llegan al ciclo mensual). Para uno esporádico cubren meses (mezclan varios ciclos). La primera etapa aprende "normalidad" con escalas de tiempo distintas por remitente.
- **Recomendación: ventana de al menos 31 días calendario** (un ciclo mensual completo: una ventana de exactamente 30 días solo contiene rezagos de 0 a 29 y no vería el de 30), con agregación diaria e indicadores de día de semana, quincena y fin de mes.
  - Es la ventana mínima que contiene los tres ciclos completos (≈4 semanas, 2 quincenas, 1 mes).
  - Una de 60 días cubriría dos ciclos mensuales, pero no cabe con el calendario disponible. Train ene–mar (≈90 días) daría apenas 1–2 ventanas independientes por remitente. Val abr–may (≈61 días) no admitiría una sola ventana de 60 días más el embargo.
- **Desviaciones:** medirlas contra el **patrón estacional propio del remitente** (su perfil por día del ciclo, estimado con meses anteriores), no contra un promedio global. Así el ciclo de salario no se confunde con riesgo.

1.3.c

- **Por qué la exactitud no sirve:** un sistema que **nunca alerta** logra 99.8% (= 1 − 0.002; 5,988 de 6,000 aciertos) y detecta **0 de 12 casos/día**. Con prevalencia de 0.2%, la exactitud la dominan los negativos y no mide el objetivo regulatorio.
- **Métricas apropiadas:**
  - **Recall (sensibilidad):** fracción de los ≈12 casos/día detectados.

    - **Precisión a la prevalencia real (0.2%)**, no a la de una validación balanceada 50/50. Ejemplo con U2 del Rol 1: 0.80 × 12 = 9.6 verdaderos positivos y 0.04 × 5,988 ≈ 240 falsos, es decir ≈ 250 alertas/día y una precisión ≈ 4% (frente a 0.95 reportado). Coincide con el piloto del Rol 7.
    - **PR-AUC / average precision**, cuyo nivel de referencia es 0.002.
    - **Recall con carga fija de alertas: recall@40 alertas/día**, la capacidad del equipo de cumplimiento (Rol 7: 8 analistas × 5).
    - **FPR y alertas diarias absolutas**, que son el costo operativo.
- **Por qué ROC-AUC también es optimista:** el FPR se divide entre ≈5,988 negativos, así que un FPR "bajo" de 0.04 son ≈240 falsas alertas/día. ROC no depende de la prevalencia y no muestra el colapso de la precisión. PR-AUC y recall@capacidad sí lo muestran.

Sección 3 del memo

Las métricas de los Roles 1 y 2 se calcularon con partición aleatoria de ventanas y están infladas por fuga de información entre ventanas del mismo remitente. Con partición temporal (ene–mar → abr–may) el AUC baja de 0.87 a 0.81. **Usar 0.81 como cifra base** y exigir validación temporal agrupada por remitente, con embargo ≥ 30 días. Por los ciclos de 7, 15 y 30 días, redefinir la ventana como al menos 31 días calendario y medir desviaciones contra el patrón propio del remitente. La exactitud (99.8% sin alertar nada) se descarta: reportar recall, precisión a 0.2% de prevalencia, PR-AUC y recall@40 alertas/día.

Cifras a compartir / dependencias

- **Grupo (Task 2.1/2.2):** AUC temporal **0.81** es la base. Toda cifra de partición aleatoria es optimista.
- **Rol 1:** la tabla de umbrales U1–U4 viene de partición aleatoria y de validación balanceada 50/50. Recall y FPR reales serán peores, y la precisión debe recalcularse a 0.2% (p. ej. U2 ≈ 4%, no 0.95). Su punto de parada temprana (época 6) también debe elegirse con validación temporal.
- **Rol 2:** el 0.87 del ajuste fino de dos bloques es de partición aleatoria. La comparación entre estrategias debe repetirse con partición temporal antes de darla por válida.
- **Rol 4:** su 0.81 → 0.83 sí es temporal y comparable con mi base. Condición: la prueba debe ser solo con datos reales de abr–may, sin sintéticos derivados de remitentes de validación (el 3% de casi copias podría filtrar información).
- **Rol 7:** recall@40 alertas/día es la métrica que conecta modelo y capacidad. El piloto con U2 (≈250 alertas, ≈4% confirmadas) confirma que la precisión a prevalencia real es baja.

Rol 4 - Especialista en modelos generativos | Task 1.4 | Memo §4

1.4.a

- **GAN (2 de 7 tipologías; repite una sola forma de fraccionamiento) → colapso de modo.** El objetivo es adversarial: el generador solo necesita engañar al discriminador, no cubrir toda la distribución de positivos. No hay término de verosimilitud ni de cobertura que lo penalice por ignorar tipologías. Si encuentra un modo que el discriminador acepta (un patrón de fraccionamiento), le conviene quedarse ahí. Por eso sus sintéticos no aportan información nueva: **el AUC no cambia**.
- **VAE (5 de 7 tipologías; secuencias borrosas) → promedio bajo incertidumbre.** Maximiza el ELBO: reconstrucción tipo gaussiana/MSE más un término KL que empuja el latente hacia N(0, I). La KL obliga a que el latente sea suave y solapado, y con pérdida MSE la mejor reconstrucción ante incertidumbre es la **media condicional**. El resultado cubre más modos que la GAN, pero promedia montos y borra los patrones exactos que definen una tipología (p. ej., montos justo bajo un umbral de reporte).
- **Difusión (6 de 7 tipologías; mayor diversidad y nitidez).** Aprende a revertir el ruido paso a paso con un objetivo de eliminación de ruido que equivale a modelar la distribución completa. No colapsa como la GAN ni promedia como el VAE. El costo: **3 días de entrenamiento** (frente a 4 h de la GAN y 2 h del VAE), y su fidelidad trae riesgo de **memorizar** muestras reales (ver 1.4.c).

1.4.b

- **Recomendación:** usar sintéticos **solo de difusión** y **solo para aumentar el entrenamiento**. Con ellos el AUC temporal pasa de **0.81 a 0.83 (+0.02)**; con la GAN no cambia, así que se descarta. El VAE no se recomienda porque pierde los patrones exactos.
- **Datos de entrenamiento:** positivos y negativos reales de **enero a marzo**, más sintéticos de difusión. El generador se entrena **solo con positivos del periodo de entrenamiento** para que no se filtre información del periodo de prueba.
- **Datos de prueba: solo datos reales** con partición temporal (validación **abril y mayo**, posterior al entrenamiento). **Nunca sintéticos**: medirían qué tan bien el modelo reconoce al generador, no qué tan bien detecta lavado real.
- **Advertencias:** +0.02 es una mejora modesta, y la tipología que ningún generador cubre (1 de 7) sigue sin representación. Hay que reportar el **recall por tipología** en la validación temporal, y no solo el AUC agregado, para confirmar que la mejora no se concentra en las tipologías que ya se detectaban.

1.4.c

El **3% de las secuencias sintéticas de difusión** son casi idénticas a secuencias reales de clientes. Eso es memorización: compartirlas o usarlas expone datos personales y financieros. Mitigación propuesta:

1. **Filtrar:** descartar cada sintético cuya distancia al vecino real más cercano quede bajo un umbral, que se fija con la auditoría de privacidad.
2. **Atacar la causa:** reentrenar con **privacidad diferencial (DP-SGD)** o, como mínimo, deduplicar el set de entrenamiento del generador para reducir la memorización.
3. **Auditar antes de usar o compartir:** prueba de **membership inference** y repetición de la auditoría de casi duplicados, con resultado documentado.
4. **Contener:** los sintéticos no salen del entorno controlado de RemesaSegura; no se comparten con terceros (p. ej., el socio del codificador).

Después del filtrado hay que **volver a medir el AUC temporal**: parte del +0.02 podría venir de las secuencias memorizadas.

Sección 4 del memo

Recomendamos usar datos sintéticos **solo de difusión** y **solo en entrenamiento**: cubre 6 de 7 tipologías y sube el AUC temporal de **0.81 a 0.83**, mientras que la GAN (2 de 7) no mejora el AUC. La prueba se hace exclusivamente con datos reales de abril y mayo. Como el **3% de los sintéticos son casi copias de clientes reales**, se exige antes del uso: filtrado por distancia al vecino real más cercano, auditoría de membership inference y prohibición de compartirlos fuera de la empresa. El +0.02 es modesto y debe confirmarse tras el filtrado con recall por tipología; la tipología restante (1 de 7) sigue sin cobertura.

Cifras a compartir / dependencias

- **Rol 3:** el AUC temporal base es **0.81** (dato del Rol 3) y con difusión sube a **0.83** (+0.02). Con GAN no cambia. La prueba es solo con datos reales de abril y mayo; hay que conciliarlo en Task 2.1 (cruce 3–4).
- **Rol 6:** el **3%** de los sintéticos de difusión son casi idénticos a clientes reales. Es un riesgo de privacidad y regulatorio que afecta la defensa ante el regulador.
- **Grupo:** el +0.02 es optimista hasta que se vuelva a medir tras el filtrado; la cobertura es de 6 de 7 tipologías; la difusión cuesta **3 días** de entrenamiento, lo que importa para el plazo del lunes. Posible condición de lanzamiento: sintéticos solo después del filtrado y la auditoría de privacidad.

Rol 5 - Líder de lenguaje natural | Task 1.5 | Memo §5

1.5.a Tasas de alucinación y su causa

Configuración	Hechos inventados	Tasa	IC 95% (Wilson, n = 40)
Sin transacciones en contexto, T = 0.7	6/40	**15%**	7.1% – 29.1%
Con transacciones en contexto, T = 0.2	2/40	**5%**	1.4% – 16.5%

- Reducción relativa: (15 − 5) / 15 = **67%**.
- **Advertencia muestral:** con 40 narrativas por configuración la estimación es muy incierta. El 5% podría ser en realidad hasta ~16.5%, y los dos intervalos se traslapan, así que la mejora es plausible pero no está demostrada estadísticamente. Hace falta una auditoría más grande antes de fijar una cifra definitiva.
- **Por qué ocurre:** un LLM genera el token más plausible condicionado al contexto; no consulta una base de hechos. Si no tiene las transacciones de la alerta, completa la narrativa con montos *verosímiles*. El USD 9,800 inventado está justo por debajo del umbral de reporte de USD 10,000 en EE. UU., un patrón "típico" de fraccionamiento que el modelo aprendió de textos de lavado. Es estadísticamente plausible y fácticamente falso.
- **Por qué ayudan contexto y temperatura:** el *grounding* (transacciones en el prompt) le da al modelo los hechos que debe copiar en lugar de inventar. Una temperatura baja (0.2) concentra el muestreo en los tokens de mayor probabilidad y reduce los desvíos creativos. **Ninguna de las dos medidas elimina el problema:** un 5% de narrativas con hechos falsos sigue siendo inaceptable en un reporte regulatorio si no hay revisión.

1.5.b Ahorro de tiempo y condiciones de uso regulado

- Ahorro por narrativa: 6 − 1.5 = **4.5 min (75%)**. Los 1.5 min ya incluyen la revisión humana.
- **Escala realista (capacidad del equipo):** 8 analistas × 5 alertas = 40 alertas/día → 40 × 4.5 = **180 min/día (3 h)** ahorrados.
- Solo como referencia, con las ~250 alertas/día del piloto el ahorro sería 1,125 min ≈ 18.75 h/día. **No es alcanzable:** el cuello de botella es la capacidad de revisión (40/día), no la redacción. El LLM no resuelve el exceso de alertas.
- **Condiciones para usarlo en un proceso regulado:**
  1. Usar solo la configuración con transacciones en contexto y **T ≤ 0.2**. La configuración sin contexto queda prohibida.
  2. El LLM produce un **borrador**: el oficial de cumplimiento lo edita, lo firma y responde por él.
  3. **Validación automática:** cada monto, fecha e ID citado debe existir en la secuencia de la alerta; si alguno no existe, la narrativa se bloquea.
  4. **Trazabilidad:** registrar el prompt, la versión del modelo, los datos usados y el editor humano.
  5. **Auditoría muestral periódica** con meta de **0 hechos inventados en narrativas enviadas** al regulador.
  6. La narrativa debe ser **consistente con la explicación SHAP** del Rol 6 (mismas variables y transacciones como motivo de la alerta).
  7. No enviar datos de clientes a servicios externos sin control (contrato, anonimización o despliegue interno).

Sección 5 del memo

Recomendamos usar el LLM solo como redactor de borradores, con las transacciones de la alerta en contexto y temperatura 0.2. Esta configuración baja las narrativas con hechos inventados de 15% a 5% (6/40 → 2/40) y ahorra 4.5 de 6 min por narrativa (75%), unos 180 min/día con las 40 alertas que el equipo puede revisar. Como 5% sigue siendo inaceptable y n = 40 deja un IC 95% de hasta ~16.5%, ninguna narrativa se envía sin que el

oficial la firme y sin que un validador automático compruebe que cada monto, fecha e ID existe en la alerta. Además exigimos trazabilidad completa, auditoría muestral con meta de 0 hechos inventados y coherencia con la explicación SHAP.

Cifras a compartir / dependencias

- → **Rol 7:** ahorro de 4.5 min/narrativa (75%); 180 min/día con 40 alertas/día (8 × 5). Las 18.75 h/día con 250 alertas no son alcanzables por capacidad. Tasas de alucinación: 15% vs 5% (IC 95% del 5%: 1.4%–16.5%). La revisión humana sigue siendo obligatoria y el LLM no amplía la capacidad de revisión.
- → **Rol 6:** la narrativa debe citar las mismas transacciones y variables que la explicación SHAP. Ninguna narrativa dirigida al cliente debe revelar qué cambiar para evitar la alerta (política de cumplimiento). El validador de hechos complementa la explicabilidad ante el regulador.
- ← **Rol 7:** capacidad de 40 alertas/día (dato usado para escalar el ahorro).

Rol 6 - Responsable de explicabilidad | Task 1.6 | Memo §6

1.6.a

- **SHAP (100 secuencias de fondo), error de eficiencia máx. 3×10^{-7} log-odds.** La propiedad de eficiencia (aditividad) se cumple: las contribuciones de cada alerta suman la diferencia entre la predicción y el valor base, con un error numérico despreciable. Esto confirma que la descomposición es exacta, pero **no** demuestra fidelidad causal ni estabilidad. Además, el valor base y las atribuciones dependen del fondo elegido (100 secuencias), así que conviene medir cuánto cambian con otros fondos.
- **LIME, 500 muestras → Jaccard 0.45 en el top-5 (20 corridas).** Para dos conjuntos de 5 variables, $J = k/(10-k)$. $J = 0.45$ equivale a $k \approx 3.1$, es decir, unas **3 de las 5** variables se repiten entre corridas ($3/7 = 0.43$). Es inestable: la misma alerta recibe explicaciones distintas en cada ejecución. **Con 5,000 muestras → 0.78** ($k \approx 4.4$, entre 4 y 5 de 5). Mejora, pero aún varía y cuesta 10× más evaluaciones del modelo.
- **Atención vs SHAP, correlación de rangos 0.35.** La concordancia es débil. La atención muestra *dónde mira* el modelo, no *cuánto contribuye* cada entrada al puntaje. No es una explicación fiel.
- **Recomendación: SHAP** como explicación oficial. **LIME no** como explicación oficial; a lo sumo como apoyo exploratorio con ≥ 5,000 muestras. **La atención no** se usa como explicación.

1.6.b

Audiencia	Qué recibe	Justificación
Oficial de cumplimiento	Top-5 variables SHAP de cada alerta, con su signo y magnitud, y las transacciones concretas que las originan (montos, fechas, contrapartes).	Necesita investigar y decidir si reporta. Las variables deben poder rastrearse hasta hechos verificables.
Regulador	Metodología (modelo de dos etapas, SHAP y su fondo), validación (AUC temporal 0.81, no 0.87 aleatoria; pruebas de estabilidad y fidelidad de 1.6.c), importancia global SHAP, registro auditable de cada alerta (puntaje, umbral, SHAP, versión del modelo, revisor y decisión) y limitaciones (dependencia del fondo, inestabilidad de LIME, atención descartada).	Obligación de explicar el motivo de cada alerta y demostrar que el sistema está controlado y es reproducible.
Cliente señalado	Comunicación genérica conforme a la ley (por ejemplo, "operación en revisión según la normativa vigente") y un canal de atención y reclamo. Nunca recibe variables, lógica del modelo ni contrafactuales. En AML normalmente ni se le informa que existe un reporte (prohibición de *tipping-off*).	Revelar la lógica le permitiría evadir el sistema y alertaría a un posible sospechoso.

1.6.c

Sentido de la política. Decirle a un cliente "qué tendría que cambiar para evitar la alerta" es un **contrafactual**. En AML funciona como un manual de evasión: por ejemplo, fraccionar montos por debajo de los umbrales o espaciar los envíos. Además, equivale a avisar al sospechoso (*tipping-off*). La política protege la eficacia del sistema y cumple la ley.

Validación adicional exigida antes del lanzamiento (los umbrales son **propuesta de Rol 6**):

1. **Fidelidad de SHAP (borrado/perturbación).** Se reemplazan las top-5 variables SHAP por valores del fondo y se mide la caída del puntaje. *Criterio propuesto:* caída media ≥ 2× la que produce borrar 5 variables al azar, en ≥ 90% de las alertas de la validación temporal (abril–mayo).
2. **Estabilidad de SHAP.** Se recalcula con 3 fondos distintos de 100 secuencias y distintas semillas. *Criterio propuesto:* Jaccard top-5 ≥ 0.90 entre fondos, por encima del 0.78 de LIME, y error de eficiencia ≤ 10^{-6}.

3. **Cero contrafactuales hacia el cliente.** Se revisan todas las plantillas y salidas dirigidas al cliente. *Criterio:* 0 salidas con variables, umbrales o sugerencias de cambio.
4. **Coherencia con las narrativas del LLM (Rol 5).** *Criterio propuesto:* 100% de las variables citadas en cada narrativa aparecen en el top-5 SHAP de su alerta y 0 transacciones inexistentes (como la de USD 9,800).

Sección 6 del memo

Recomendamos SHAP como explicación oficial de cada alerta: su error de eficiencia es ≤ 3×10^{-7} log-odds, así que la descomposición es exacta. LIME es inestable (Jaccard top-5 de 0.45 con 500 muestras, ≈ 3 de 5 variables; 0.78 con 5,000, a 10× el costo) y la atención no explica el puntaje ($\rho = 0.35$ con SHAP). El oficial recibe el top-5 SHAP con sus transacciones; el regulador, la metodología, el AUC temporal 0.81 y un registro por alerta; el cliente, solo un aviso legal genérico, sin contrafactuales (*tipping-off*). Condición de lanzamiento: aprobar las pruebas de fidelidad y estabilidad de SHAP (Jaccard ≥ 0.90 entre fondos, propuesta) y que el 100% de las narrativas LLM coincidan con SHAP.

Cifras a compartir / dependencias

- **Rol 5:** cada narrativa debe citar solo variables del top-5 SHAP y transacciones reales de la alerta (criterio de 100% de coincidencia). Las narrativas no salen hacia el cliente.
- **Rol 7:** el oficial recibe el top-5 SHAP y sus transacciones, lo que agiliza la revisión. LIME a 5,000 muestras cuesta 10× y no se usa en el flujo diario. El registro por alerta es un requisito operativo.
- **Rol 3 / grupo:** al regulador se le reporta el AUC temporal 0.81, no el 0.87 de la partición aleatoria.
- **Rol 4 / grupo:** el fondo SHAP debe salir de datos reales, no de sintéticos de difusión (3% casi duplicados de clientes reales).
- **Grupo (defensa regulatoria):** SHAP con eficiencia 3×10^{-7}; LIME 0.45 → 0.78; atención $\rho = 0.35$ (descartada); prohibición de contrafactuales y *tipping-off*; pruebas de fidelidad y estabilidad como condición medible de lanzamiento.

Rol 7 - Responsable de operaciones y cumplimiento | Task 1.7 | Memo §7

Datos: 8 analistas × 5 alertas/día; USD 12 por alerta; piloto de 2 semanas con U2: ≈250 alertas/día, ≈4% confirmadas; 12 casos/día esperados; USD 50,000 por caso no detectado. **Cada alerta debe ser revisada por una persona de cumplimiento.**

1.7.a

- **Capacidad diaria:** 8 × 5 = **40 alertas/día**. Revisarlas cuesta 40 × 12 = **USD 480/día**.
- **Costo de revisar todo el piloto:** 250 × 12 = **USD 3,000/día**.
- **Comparación:** las alertas superan la capacidad **6.25×** (250 / 40). Quedan **210 alertas/día sin revisar (84%)**, y eso no se puede aceptar porque toda alerta requiere revisión humana. Para revisar 250 se necesitan 250 / 5 = **50 analistas (42 más)**.

1.7.b

- **Confirmados detectados en el piloto:** 4% × 250 = **10 casos/día**, es decir **10 / 12 = 83%** de los casos esperados (recall ≈ 0.83). Es consistente con el recall 0.80 de U2 del Rol 1: 0.80 × 12 = 9.6/día.
- **Cifra a conciliar:** la precisión real del piloto es **≈4%**, y el Rol 1 reportó **0.95** en validación remuestreada 50/50. Con la prevalencia real, U2 da 9.6 VP + 0.04 × 5,988 = 239.5 FP ≈ 249 alertas, con una precisión de ≈3.9%. Eso reproduce el piloto, así que el 0.95 solo vale para una muestra balanceada.
- **No detectados:** 12 − 10 ≈ **2 casos/día**, que dan 2 × 50,000 = **USD 100,000/día** de daño esperado.
- **Cifra optimista a conciliar (Task 2.1):** con 40 revisiones/día, el equipo no pudo revisar las ≈250 alertas/día del piloto (≈3,500 en dos semanas frente a ≈560 revisiones posibles). El «4% confirmadas» tuvo que salir de una muestra o de personal adicional, y el 83% de detección compara contra los 12 casos/día *esperados*, no contra casos perdidos medidos. Ambas cifras deben tratarse como estimaciones, no como mediciones.

1.7.c

Base: 6,000 remitentes/día con 0.2% de prevalencia (12 positivos y 5,988 negativos), tabla del Rol 1. Aquí solo calculo lo necesario para la recomendación. La tabla completa de umbrales es grupal (Task 2.2).

Opción	Alertas/día	Detectados	No detectados → daño/día	Revisión/día
(i) U2, revisar solo las 40 de mayor puntaje	40 de ≈250	≥1.6 (sin dato del piloto)	≥10.4 → ≤USD 520,000	USD 480
(ii) Subir a U4	6 + 29.9 ≈ 36	6	6 → USD 300,000	≈USD 431
(ii) Subir a U3	7.8 + 59.9 ≈ 68	7.8	4.2 → USD 210,000	≈USD 812 (14 analistas)
(iii) Ampliar capacidad para U2	≈250	9.6 (piloto: 10)	2.4 → USD 120,000	≈USD 3,000 (50 analistas)

- **(i) Priorizar por puntaje:** si las 40 alertas revisadas tuvieran la precisión del piloto (~4%), saldrían 40 × 0.04 = **1.6 casos/día**. Ordenar por puntaje debería dar más, pero el piloto no lo mide. Si el puntaje ordena igual que la tabla del Rol 1, las 40 de mayor puntaje se parecen mucho a U4, que tiene 36 alertas. Además, las otras 210 alertas que genera U2 quedarían sin revisar, lo que choca con la regla de revisión humana.
- **(ii) Subir el umbral:** U4 es la única opción que cabe hoy en 40, pero detecta solo **6 de 12**. Eso deja 6 × 50,000 = **USD 300,000/día** de daño esperado. U3 detecta 7.8 con ≈68 alertas, lo que requiere ampliar el equipo a 14

analistas (6 más).

- **(iii) Ampliar capacidad** (contratación, personal temporal u outsourcing supervisado): pasar de U4 a U2 cuesta en revisión ≈(249.1 − 35.9) × 12 = **USD 2,558/día** adicionales (misma base que el beneficio). A cambio detecta ≈3.6 casos más que U4 (9.6 − 6), es decir 3.6 × 50,000 = **USD 180,000/día** de daño evitado. El beneficio supera al costo unas 70 veces, aunque el costo de contratar no viene en los datos.
- **LLM con transacciones en contexto (Rol 5):** la narrativa baja de 6 a 1.5 min, un ahorro de 4.5 min por alerta (≈18.75 h/día con 250 alertas). Tiene 2/40 = 5% de hechos inventados, así que siempre requiere revisión humana. No conozco el tiempo total de revisión por alerta, por eso no puedo convertir ese ahorro en alertas/analista adicionales.
- **Recomendación escalonada (lanzar con condiciones):**
  1. **Inmediato:** operar en **U4** (≈36 ≤ 40 alertas/día), con el 100% de las alertas revisadas por una persona.
  2. **Corto plazo:** ampliar a 14 analistas y bajar a **U3**.
  3. **Meta:** llegar a ≈50 analistas o capacidad equivalente y operar en **U2**, solo cuando la cola sin revisar sea 0 y el recall del piloto sea ≥0.80.
  4. **Narrativas:** usar el LLM con contexto, con revisión obligatoria.
  5. **Seguimiento:** medir semanalmente las alertas/día, las confirmaciones y los casos perdidos.

Sección 7 del memo

El equipo revisa 40 alertas/día (8 × 5). U2 genera ≈250 en el piloto (USD 3,000/día), así que 210 alertas (84%) quedarían sin revisión humana. El piloto confirma 10/día (83% de 12) con una precisión real ≈4%, frente al 0.95 reportado en validación 50/50. Recomendamos **lanzar con condiciones**: empezar en U4 (≈36 alertas, cabe en la capacidad) sin dejar alertas sin revisar, y ampliar capacidad hacia U3 (14 analistas) y luego U2 (50). Cada caso adicional detectado evita USD 50,000, y pasar de U4 a U2 evita ≈USD 180,000/día a un costo de revisión de ≈USD 2,558/día.

Cifras a compartir / dependencias

- **Capacidad:** 40 alertas/día (8 analistas × 5). Se necesitan 5 analistas por cada 25 alertas.
- **Costo:** USD 12 por alerta. USD 480/día con la capacidad actual y USD 3,000/día para revisar todo el piloto con U2.
- **Piloto U2:** ≈250 alertas/día, 4% confirmadas, 10 detectados/día (83%) y ≈2 no detectados/día.
- **Daño:** USD 50,000 por caso no detectado (en el piloto: ≈USD 100,000/día).
- **Para Rol 1 / Task 2.2:** la precisión real (≈4%) contradice el 0.95 de la validación 50/50. Todo umbral que pase de 40 alertas/día exige ampliar capacidad antes de operar.
- **Depende de Rol 5:** tasa de alucinación (5% con contexto) y ahorro de 4.5 min por narrativa.