Memo del comité técnico: lanzamiento del sistema de detección de lavado

RemesaSegura S.A. · Para: Gerencia General · Base: 6,000 remitentes/día, prevalencia 0.2% (12 casos/día) · CC3045 Deep Learning

Decisión: LANZAR CON CONDICIONES. El lunes operamos en **U4 con los 8 analistas actuales** (≈36 alertas/día de 40 revisables, USD 431/día), para que toda alerta tenga revisión humana. Bajamos a U3 (14 analistas) y a U2 (50 analistas, ≈250 alertas/día, USD 3,000/día) a medida que crezca la capacidad y se revalide el modelo. U4 deja ≈6 de 12 casos/día sin detectar (≈USD 300,000/día de daño esperado); U2 lo reduce a 2.4 (USD 120,000).

1. Modelado y entrenamiento (Rol 1)

El modelo evaluado (época 20) está sobreajustado: la pérdida de validación subió de 0.21 (época 6) a 0.34. Recomendamos reentrenar con parada temprana (restaurando el mejor checkpoint), *weight decay* y *dropout*, y BCE ponderada (`pos_weight` hasta 499) o focal loss, con recalibración. La precisión reportada de 0.90–0.99 viene de una validación 50/50: con la prevalencia real es de 1.8% (U1) a 16.7% (U4), y en U2 es **3.9% con ≈249 alertas/día**. Ningún umbral es definitivo hasta recalcular la tabla con el modelo corregido.

2. Transferencia y ajuste fino (Rol 2)

Adaptamos el codificador del socio con **ajuste fino de los dos últimos bloques y LR 10× menor**: es la mejor estrategia evaluada (AUC 0.87), con 18% de parámetros entrenables y 1.5 GPU-h. El ajuste completo da 0.84 porque sobreajusta con solo 1,200 positivos y olvida lo aprendido de 3 millones de secuencias. LoRA r=8 (0.86, 2%, 1 GPU-h) queda como alternativa. **A la gerencia se le reporta el AUC temporal 0.81, no 0.87.** Antes de lanzar: re-normalizar los montos a la escala del socio y medir la deriva entre corredores (PSI o KS).

3. Validación temporal y métricas (Rol 3)

Las métricas de los Roles 1 y 2 usan partición aleatoria de ventanas, con fuga entre ventanas del mismo remitente. Con partición temporal (ene–mar → abr–may) el AUC baja de 0.87 a **0.81**, la cifra base. Exigimos validación temporal agrupada por remitente con embargo ≥ 30 días. Por los ciclos de 7, 15 y 30 días (pago semanal, quincenal y mensual), la ventana debe ser de al menos 31 días calendario. La exactitud no sirve (99.8% sin emitir una sola alerta): reportamos recall, precisión a prevalencia real, PR-AUC y recall@40 alertas/día.

4. Datos sintéticos y privacidad (Rol 4)

Usamos sintéticos **solo de difusión y solo en entrenamiento**: cubre 6 de 7 tipologías y sube el AUC temporal de **0.81 a 0.83**. La GAN (2 de 7, colapso de modo) no mejora y el VAE (5 de 7) promedia montos y produce secuencias borrosas. La prueba usa solo datos reales de abril y mayo. Como el **3% de los sintéticos son casi copias de clientes**, antes de usarlos se filtran por distancia al vecino real más cercano, se hace una auditoría de membership inference y no se comparten fuera de la empresa. La mejora de +0.02 debe confirmarse tras el filtrado.

5. Narrativas con LLM (Rol 5)

El LLM solo redacta borradores, con las transacciones de la alerta en contexto y temperatura 0.2. Los hechos inventados bajan de **15% a 5%** (6/40 → 2/40) y el ahorro es de 4.5 de 6 min por narrativa (75%), ≈180 min/día con 40 alertas. Como 5% sigue siendo inaceptable (IC 95% hasta 16.5% con n = 40), ninguna narrativa sale sin la firma del oficial ni sin un validador automático que compruebe que cada monto, fecha e ID existe en la alerta. Exigimos trazabilidad completa y coherencia con SHAP.

6. Explicabilidad (Rol 6)

SHAP es la explicación oficial: su error de eficiencia es ≤ $\mathbf{3\times10^{-7}}$ log-odds, así que la descomposición es exacta. LIME es inestable (Jaccard top-5 de 0.45 con 500 muestras, ≈3 de 5 variables; 0.78 con 5,000) y la atención no explica el puntaje (ρ = 0.35 con SHAP). El oficial recibe el top-5 SHAP con sus transacciones; el regulador, la metodología, el AUC 0.81 y un registro por alerta; el cliente, solo un aviso legal genérico, sin contrafactuales, porque enseñarían a evadir el sistema (*tipping-off*). Antes de lanzar, SHAP debe pasar pruebas de fidelidad y estabilidad.

7. Operaciones y cumplimiento (Rol 7)

El equipo revisa **40 alertas/día** (8 × 5). U2 generó ≈250 en el piloto (USD 3,000/día): 210 (84%) quedarían sin revisión humana. El piloto confirma ≈10/día (83% de 12) con precisión real ≈4%. Por eso arrancamos en U4 (≈36 alertas) sin dejar alertas sin revisar y ampliamos capacidad hacia U3 (14 analistas) y U2 (50). Pasar de U4 a U2 cuesta ≈USD 2,558/día en revisión y evita ≈USD 180,000/día en daño esperado.

Umbral, capacidad y condiciones (Task 2.2)

Umbral	Alertas/día	Detectados	No detectados	Precisión	Revisión/día	Daño esperado/día	Analistas
U1	609.6	10.8	1.2	1.8%	USD 7,315	USD 60,000	122
U2	249.1	9.6	2.4	3.9%	USD 2,989	USD 120,000	50
U3	67.7	7.8	4.2	11.5%	USD 812	USD 210,000	14
U4	35.9	6.0	6.0	16.7%	USD 431	USD 300,000	8

Solo U4 cabe en 40 revisiones/día. Cada paso hacia un umbral más bajo evita mucho más daño del que cuesta revisar (U4→U3: USD 381 por USD 90,000). U2 es el objetivo porque es el único punto que el piloto corrobora (≈250 alertas, ≈10 confirmados).

U1 exige 122 analistas y no está validado. **Condiciones medibles:**

1. 0 alertas sin revisar por día; alertas/día ≤ 5 × analistas activos (U3 con ≥ 14 analistas, U2 con ≥ 50).
2. Antes de bajar de U4: modelo reentrenado y validado con partición temporal por remitente, con AUC ≥ 0.81 y recall ≥ 0.80 en el umbral objetivo.
3. Narrativas: 100% pasan el validador automático y 0 hechos inventados en la auditoría mensual (≥ 40 narrativas).
4. SHAP aprueba las pruebas de fidelidad y estabilidad (Jaccard top-5 ≥ 0.90, propuesta) y hay 0 contrafactuales al cliente.
5. Sintéticos solo tras el filtrado de privacidad (0 casi duplicados); deriva de montos monitoreada mensualmente.

Cifras que no cuadraron y cómo se resolvieron

Precisión 0.95 vs ≈4%: 0.95 sale de la validación 50/50 y 4% de la prevalencia real. Recall y FPR se conservan, la precisión no; se usa 3.9%. **AUC 0.87 vs 0.81:** partición aleatoria (con fuga) frente a temporal; se usa 0.81. **AUC 0.83:** es temporal pero previo al filtrado de privacidad, así que no entra en la decisión. **Tabla U2 (249 alertas, 9.6 TP) vs piloto (≈250, 10):** coinciden, lo que corrobora U2; U3 y U4 no están validados. **40 vs 250 alertas/día:** son oferta y demanda; la brecha obliga a U4 al inicio. **Cifras optimistas:** precisión 0.90–0.99, AUC 0.87, 0.83 sin filtrar, 5% de alucinación (n = 40) y el piloto mismo. Con 40 revisiones/día no se pudieron revisar las 250 alertas, así que el 4% viene de una muestra, y el 83% compara contra una estimación de 12 casos.

Crítica de la IA

(1) La IA justificó la BCE ponderada con "un predictor constante obtiene pérdida 0.014", sin notar que contradice la pérdida de entrenamiento de 0.08 del caso. Lo verificamos a mano: $-(0.002 \cdot \ln 0.002 + 0.998 \cdot \ln 0.998) = 0.0144$. (2) La IA mezcló bases al calcular U4→U2: cobró 210 × 12 = USD 2,520 contra la capacidad actual, pero midió el beneficio contra U4. Recalculado con la misma base: (249.1 − 35.9) × 12 = USD 2,558. (3) La IA tomó el 4% y el 83% del piloto sin cuestionar cómo se revisaron 250 alertas con capacidad para 40. (4) La IA propuso una ventana de 30 días para captar el rezago de 30, cuando esa ventana solo contiene rezagos de 0 a 29; se corrigió a ≥ 31 días. (5) La IA aplicó la tabla del Rol 1 a producción sin ajustarla por la caída a AUC temporal 0.81; el piloto solo la corrobora para U2.

Defensa ante el regulador

Presentamos la validación temporal (AUC 0.81, ene–mar → abr–may), el piloto de dos semanas en U2 (≈250 alertas/día, ≈10 confirmados/día), las explicaciones SHAP por alerta (error 3×10^{-7}) y el registro auditable de la revisión humana de cada alerta. Reconocemos un riesgo residual: hasta ampliar el equipo, U4 deja ≈6 de 12 casos/día sin detectar, y el modelo puede degradarse por deriva del corredor. Nos comprometemos a informar mensualmente recall, precisión, deriva de montos, la auditoría de narrativas y una cola sin revisar en 0, y a bajar a U3 y luego a U2 conforme crezca la capacidad. La decisión la asume la Gerencia General a propuesta de este comité; el Oficial de Cumplimiento responde por la operación y el reporte.

Contribuciones individuales

Integrante (rol)	Aporte	Corrección a la IA y cómo se verificó	Dato que necesitó de otro rol
José Ruíz (1)	Diagnóstico de sobreajuste, pérdida ponderada y precisión real	La IA citó una pérdida de 0.014 para un predictor constante sin notar que contradice el 0.08 de entrenamiento; se recalculó a mano: 0.0144	Piloto de 250 alertas (Rol 7)
José Auyón (2)	Elección de ajuste fino de 2 bloques y riesgos de transferencia	La IA ordenó las estrategias con AUC de partición aleatoria; al cruzarlo con el Rol 3, solo la elegida tiene AUC temporal (0.81) y el orden de las demás no está validado	AUC temporal 0.81 (Rol 3)
Gerardo Fernández (3)	Validación temporal, ventana y métricas	La IA propuso una ventana de 30 días para captar el rezago de 30; esa ventana solo tiene rezagos de 0 a 29, así que se corrigió a ≥ 31 días	Capacidad de 40/día para recall@40 (Rol 7)
David Juárez (4)	Recomendación de difusión y mitigación de privacidad	La IA propuso filtrar por distancia sin fijar un umbral; el README no da ninguno, así que se definió como criterio 0 casi duplicados tras la auditoría	Base 0.81 (Rol 3)
Juan Diego Solis (5)	Tasas de alucinación, ahorro y controles del LLM	La IA afirmó que el ahorro de 4.5 min no aumenta la capacidad; el caso no da el tiempo de revisión por alerta, así que quedó como limitación y no como conclusión	Capacidad 40/día (Rol 7) y SHAP (Rol 6)
Dillary Cruz (6)	Explicación SHAP por audiencia y validación previa	La IA presentó criterios (Jaccard ≥ 0.90, fidelidad 2× frente al azar) que no salen de los datos; se comprobó en el README y se marcaron como propuesta	AUC 0.81 (Rol 3) y narrativas (Rol 5)
Alex de la Cruz (7)	Capacidad, costos y plan escalonado	La IA calculó U4→U2 como 210 × 12 = USD 2,520 mezclando bases; con la misma base: (249.1 − 35.9) × 12 = USD 2,558	Tabla de umbrales (Rol 1)